



گزارش چالش بوت کمپ مهندسی داده همراه اول

پارسا اسدنژاد

تحلیل مقیاس پذیری و مدیریت حجم بالای داده

اگر تعداد داده‌ها از چند ده رکورد در ثانیه به هزاران یا حتی ۵۰'۰۰۰ رکورد در ثانیه افزایش پیدا کند، معماری ساده‌ی Python و ذخیره مستقیم در CSV دیگر مناسب نخواهد بود. در این حالت، دریافت، پردازش و ذخیره‌سازی داده‌ها نباید همگی در یک بخش انجام شوند. برای مقیاس بالاتر، بهتر است این مراحل از یکدیگر جدا شوند. داده‌ها ابتدا در یک صف پیام مانند Kafka قرار می‌گیرند. سپس چند پردازشگر به صورت هم‌زمان داده‌ها را پردازش و اعتبارسنجی می‌کنند. در مرحله آخر، داده‌ها به صورت دسته‌ای در یک سیستم مناسب مانند ClickHouse، TimescaleDB یا Parquet ذخیره می‌شوند. این معماری باعث می‌شود با افزایش تعداد ایستگاه‌ها و حجم داده، بتوان تعداد پردازشگرها و منابع سیستم را افزایش داد و از ایجاد گلوگاه در دریافت، پردازش و ذخیره‌سازی جلوگیری کرد.

۲. معماری مدیریت چند جریان هم‌زمان (سوکت‌های مستقل به ازای هر مدل)

برای پردازش هم‌زمان چند سوکت مجزا، پیاده‌سازی بر پایه **رویکرد ناهمگام (Async I/O یا asyncio)** یا مدل چندرشته‌ای (Multi-threading) همراه با صف مشترک ضروری است. در این ساختار، به ازای هر اتصال یک Task یا Thread مجزا برای دریافت، بافرینگ و پارس اولیه داده‌ها اختصاص می‌یابد، اما جهت جلوگیری از تداخل و مسابقه داده‌ها (Race Condition)، تمامی داده‌های پردازش شده به یک صف thread-safe هدایت می‌شوند تا یک نویسنده واحد (Single-Writer) آن‌ها را روی دیسک بنویسد. علاوه بر این، مکانیزم گزارش‌گیری ۲۰ ثانیه‌ای باید از چرخه دریافت رویدادها کاملاً جدا شود؛ به طوری که یک تایمر مستقل و دوره‌ای، معیارهای تجمیعی را به صورت Thread-safe از ساختارهای مشترک خوانده، در گزارش ثبت و سپس شمارنده‌ها را بازنشانی کند.

۳. راهکارهای تضمین عدم اتلاف داده (Zero Data Loss)

برای جلوگیری از دست رفتن داده‌ها در صورت قطع اتصال، خطای پایگاه داده یا Crash شدن برنامه، داده‌های دریافتی ابتدا در یک صف یا محل ذخیره موقت نگهداری می‌شوند. پس از ذخیره موفق داده در پایگاه داده، یک پیام تأیید (ACK) برای فرستنده ارسال می‌شود. اگر ذخیره‌سازی با خطا مواجه شود، داده حذف نمی‌شود و برای پردازش دوباره نگهداری می‌شود. برای جلوگیری از ذخیره شدن دوباره یک داده، هر رکورد یک reading_id یکتا دارد. همچنین در صورت قطع اتصال، سیستم به صورت خودکار دوباره برای اتصال تلاش می‌کند. به این ترتیب، داده‌ها حتی در شرایط خطا نیز قابل بازیابی هستند.